


SI7011 · Evento evaluativo 1 · Parte A: leer la evidencia

Nombre: _____

Documento: _____

Individual · sin computador ni apuntes · 30 minutos · 6 preguntas, 1 punto cada una.
Respuestas cortas: una o dos frases por literal. Cuando la pregunta pide evidencia, cita un número leído de la figura.

1. Dos corridas



a) Diagnostica cada corrida en una frase, citando lo que ves en las curvas.

b) Propón **una** acción para cada corrida y di qué cambio en las curvas confirmaría que funcionó.

2. Un cálculo de varianza

Una capa ReLU con $n_{\text{in}} = 400$ y pesos $W \sim \mathcal{N}(0, 0.05^2)$. Supón que ReLU conserva la mitad de la varianza.


a) ¿Por qué factor se multiplica $\text{Var}(a_l)$ en cada capa?

b) Después de 10 capas, ¿cuánto vale $\text{std}(a_{10})$ en proporción a la inicial?

c) ¿Qué desviación estándar σ conserva la varianza? ¿Cómo se llama esa inicialización?

3. Tres inicializaciones

Un MLP de 15 capas ocultas con ReLU y 256 unidades, medido **antes de entrenar** sobre un lote, con tres inicializaciones: la de PyTorch por defecto, Xavier y He (en algún orden).



a) Asigna I, II y III a {PyTorch por defecto, Xavier, He}. Justifica cada una con un número de las gráficas.

b) ¿Cuál entrenarías con SGD? ¿Qué les pasaría a las primeras capas con las otras dos?

4. La pérdida inicial

Un problema con $C = 7$ clases balanceadas. Tres compañeros reportan la pérdida de **validación antes de entrenar** (entropía cruzada). Interpreta cada valor en una frase: ¿está bien? Si no, ¿qué sospechas?


a) 1.95

b) 38.2

c) 0.03

5. Tamaño del lote



El mismo modelo con el mismo $\eta = 0.05$ durante 3 épocas. Una corrida usa lotes de 16 y la otra lotes de 1024. Corrida P: 0.14 s por época. Corrida Q: 0.82 s por época.



a) ¿Cuál corrida usa lotes de 16? Da dos razones que se vean en la figura o en los tiempos.

b) Si pasas de lotes de 16 a 1024 y quieres avanzar lo mismo por época, ¿qué haces con η ? ¿Para qué sirve un *warmup*?

6. Profundidad y weight decay



a) Un estudiante dice: «la red de 40 capas sobreajusta; hay que agregarle Dropout». ¿Estás de acuerdo? Justifica con las curvas y propón qué cambiarías.

b) `torch.optim.Adam(..., weight_decay= $\lambda$ )` frente a `torch.optim.AdamW(..., weight_decay= $\lambda$ )`: ¿qué hace cada uno con la penalización, y por qué se prefiere AdamW?