# SI7011 · Evento evaluativo 2 · Parte A: leer la evidencia

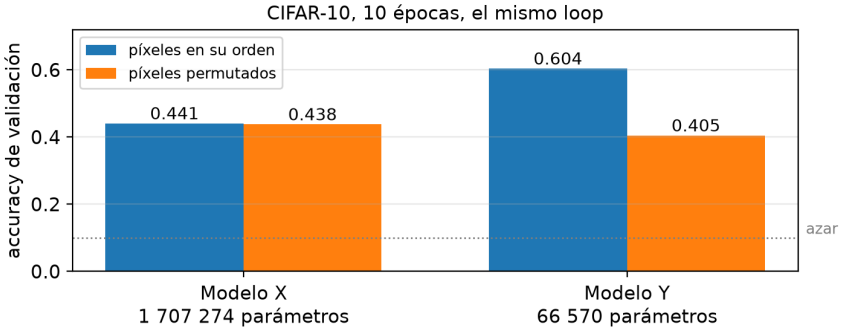
**Nombre:** _____ **Documento:** _____

**Individual · sin computador ni apuntes · 30 minutos · 6 preguntas, 1 punto cada una.** Respuestas cortas: una o dos frases por literal. Cuando la pregunta pide evidencia, cita un número leído de la figura o la tabla. Todos los resultados son de corridas reales de los notebooks de la sesión 03.

---

## 1. Permutar los píxeles

Uno de los modelos es un MLP sobre la imagen aplanada y el otro una CNN pequeña. «Permutados» quiere decir que se baraja el orden de los píxeles con **una misma permutación fija** para todas las imágenes (entrenamiento y validación) y se entrena de nuevo.




a) ¿Cuál es el MLP y cuál la CNN? Justifica con dos números de la figura.

b) ¿Por qué la permutación casi no afecta a uno y sí al otro? Nombra la suposición sobre la imagen que se rompe.

## 2. Formas, parámetros y campo receptivo

Una imagen de EuroSAT de $3 \times 64 \times 64$ entra a:

`Conv2d(3, 32, kernel_size=3, padding=1)` → ReLU →
`Conv2d(32, 64, kernel_size=3, padding=1, stride=2)` → ReLU → `MaxPool2d(2)`

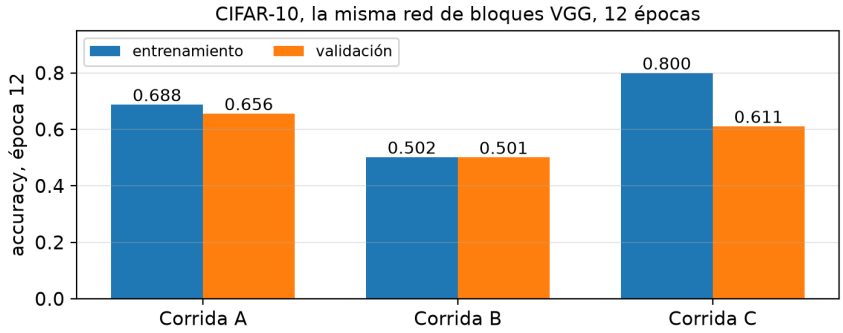
a) Escribe la forma $C \times H \times W$ de la salida de cada una de las tres capas.

b) ¿Cuántos parámetros tiene la segunda convolución? ¿Cuántos tendría una capa densa con la misma entrada y la misma salida? ¿Qué dos propiedades de la convolución explican la diferencia?

c) ¿Qué región de la imagen de entrada ve una posición a la salida de la segunda convolución? ¿Y a la salida del `MaxPool2d`?

## 3. BatchNorm y data augmentation

Las tres corridas usan la misma red de bloques VGG: una **sin** BatchNorm, otra **con** BatchNorm, y otra con BatchNorm **y** data augmentation (recortes y flip horizontal).




a) Asigna A, B y C. Justifica cada una con un número de la figura.

b) Una corrida tiene **menos** accuracy de entrenamiento que otra pero **más** en validación. Explica por qué, y di qué número calcularías para mostrarlo.

## 4. Profundidad y atajos

Dos redes de 20 capas convolucionales con BatchNorm, sobre CIFAR-10: las mismas convoluciones, la misma inicialización, los mismos datos y la misma augmentation, 8 épocas. Una tiene atajos residuales y la otra no.

| | parámetros | pérdida de entrenamiento | acc. entrenamiento | acc. validación |
|---|---|---|---|---|
| Red P | 269 722 | 1.189 | 0.565 | 0.529 |
| Red Q | 272 474 | 0.992 | 0.639 | 0.606 |

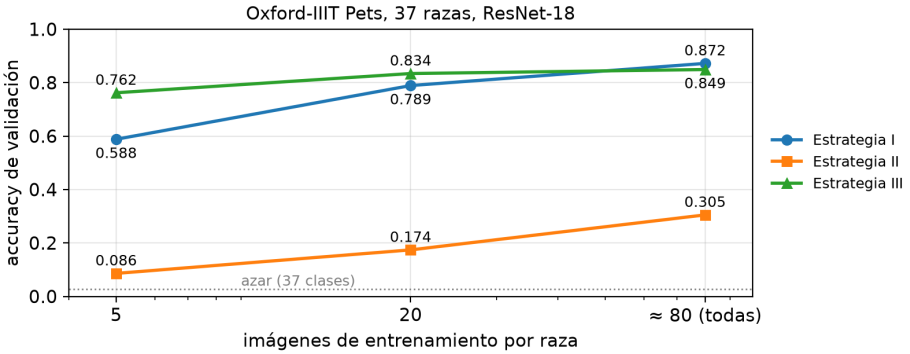
a) Un compañero dice: «la red P sobreajusta». ¿Estás de acuerdo? Justifica con dos números de la tabla.

b) ¿Cuál red tiene atajos? Escribe la salida de un bloque residual en función de su entrada $a_l$ y explica por qué el atajo ayuda a entrenar una red profunda.

c) Q tiene 2 752 parámetros más que P. ¿De dónde salen, si los atajos suelen ser la identidad?

## 5. Tres estrategias de transfer learning

Una ResNet-18 sobre Oxford-IIIT Pets (37 razas) con tres estrategias: entrenar **desde cero**, *linear probe* sobre el backbone de ImageNet **congelado**, y *fine-tuning* de toda la red partiendo de ImageNet.




a) Asigna I, II y III. Justifica cada una con un número de la figura.

b) Con 5 imágenes por raza, I queda por debajo de III; con todas, la supera. Explica por qué.

c) En el fine-tuning, el backbone usa $\eta = 10^{-4}$ y la cabeza nueva $\eta = 10^{-3}$. ¿Por qué no usar el mismo $\eta$ para toda la red?

## 6. CNN frente a ViT

CIFAR-10, 50 000 imágenes de entrenamiento. Las tres primeras filas se entrenan desde cero con el mismo loop durante 20 épocas.

| Modelo | parámetros | acc. validación | tiempo |
|---|---|---|---|
| CNN (bloques VGG + BatchNorm) | 72 954 | 0.693 | 21 s |
| ViT pequeño (patches $4 \times 4$, $d = 128$, 6 bloques) | 811 146 | 0.603 | 75 s |
| El mismo ViT sin embeddings de posición | 811 146 | 0.551 | 78 s |
| ViT-B/16 preentrenado en ImageNet + *linear probe* | $\approx 86$ M | 0.943 | — |

a) El ViT pequeño tiene 11 veces más parámetros y aun así pierde contra la CNN, pero el ViT-B/16 preentrenado le gana. Explica las dos cosas.

b) Sin embeddings de posición, ¿qué información pierde el modelo? ¿Por qué aun así queda muy por encima del azar (0.10)?

c) Con imágenes de $32 \times 32$ y patches de $4 \times 4$, ¿cuántos tokens entran al Transformer, contando `[CLS]`? Con imágenes de $64 \times 64$ y los mismos patches, ¿cuántos, y por qué factor crece la matriz de atención?