SI7011 · Evento evaluativo 3 · Parte A: leer la evidencia

Nombre: _____ **Documento:** _____

Individual · sin computador ni apuntes · 45 minutos · 8 preguntas, 1 punto cada una. Respuestas cortas: una o dos frases por literal. Cuando la pregunta pide evidencia, cita un número leído de la figura o la tabla. Todos los resultados son de corridas reales de los notebooks de las sesiones 05 y 06.

---

1. Partir una serie de tiempo

Jena Climate: ventanas de 120 horas, predecir la temperatura 24 horas después. La línea base dice «la temperatura en 24 h será la de ahora». El mismo MLP se entrena con dos particiones: **en el tiempo** (el primer 50 % entrena, el siguiente 25 % valida) o **barajada** (se barajan las ventanas del primer 75 % y se separan al azar). La prueba es siempre el último 25 % de la serie.

MAE (°C)	validación	prueba
línea base	2.44	2.62
MLP, partición en el tiempo	2.50	2.67
MLP, partición barajada	2.30	2.57

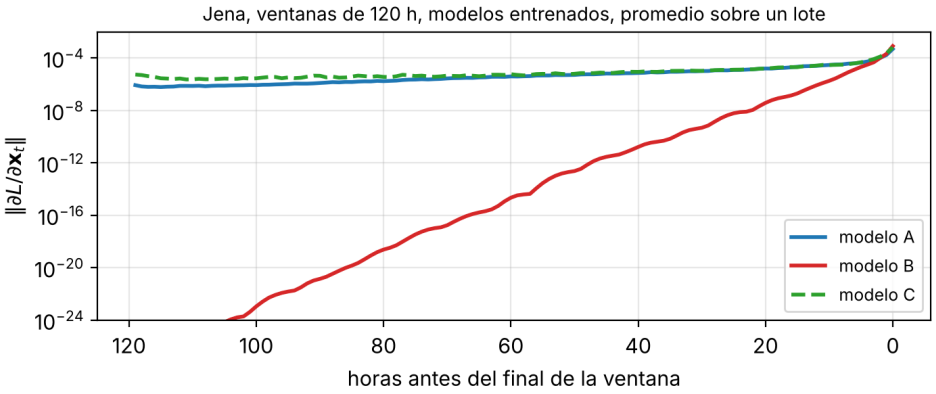
a) Con la partición barajada, la validación promete que el MLP mejora a la línea base en 0.14 °C. ¿Cuánto la mejora en prueba? ¿Y con la partición en el tiempo, qué habría dicho la validación? Usa números de la tabla.

b) ¿Por qué barajar las ventanas antes de partir produce una fuga, si ninguna ventana aparece dos veces?

c) La temperatura media del bloque de entrenamiento es 8.82 °C y la de toda la serie 9.44 °C. ¿Con cuál se normaliza, y por qué?

2. El gradiente a lo largo de la ventana

Tres modelos recurrentes entrenados en la misma tarea: una RNN simple, una LSTM y una GRU. La figura muestra cuánto cambia la pérdida con cada hora de la entrada.



	parámetros	MAE validación (°C)
línea base	0	2.44
RNN, ventana de 120 h	529	2.33
RNN, ventana de 24 h	529	2.33
LSTM, ventana de 120 h	2 065	2.32
GRU, ventana de 120 h	1 553	2.30

a) ¿Cuál curva es la RNN simple? Justifica con un valor leído de la figura y explica de dónde sale esa forma.

b) ¿Qué tiene la celda de la LSTM que evita esa forma?

c) La RNN da el mismo MAE con 120 h y con 24 h de ventana. ¿Qué dice eso, junto con la figura? Si la LSTM conserva el gradiente, ¿por qué casi no le gana a la RNN en esta tarea?

3. Barajar las palabras

IMDB, 20 000 reseñas de entrenamiento. Tres clasificadores: una **bolsa de embeddings** (promedio de los vectores de las palabras), una **CNN 1-D** y una **LSTM**. «Barajado» quiere decir que en el test se barajan las palabras de cada reseña, sin volver a entrenar.

	parámetros	acc. test	acc. test barajado
Modelo X	1 292 545	0.841	0.796
Modelo Y	1 280 193	0.854	0.854
Modelo Z	1 313 473	0.826	0.807

a) ¿Cuál es la bolsa de embeddings? Justifica con la tabla y explica por qué ese resultado es exacto, no una casualidad.

b) ¿Qué dice este experimento sobre si clasificar el sentimiento de una reseña necesita un modelo que tenga en cuenta el orden?

c) Con embeddings GloVe preentrenados **congelados**, la bolsa da 0.753; con GloVe **ajustados** a IMDB, 0.859. ¿Por qué la diferencia, si los dos parten de los mismos vectores?

4. El cuello de botella del seq2seq

Fechas en palabras a formato ISO: «el primero de mayo de 2 0 2 6» → `2026-05-01`. El encoder y el decoder son GRU de tamaño d. Exactitud por posición de la salida:

	parám.	exacta	año			-		mes		-	día	
sin atención, $d = 24$	14 204	0.004	1.00	1.00	0.98	0.95	1.00	0.76	**0.15**	1.00	**0.32**	**0.09**
sin atención, $d = 96$	99 020	1.000	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
con atención, $d = 24$	16 220	1.000	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00

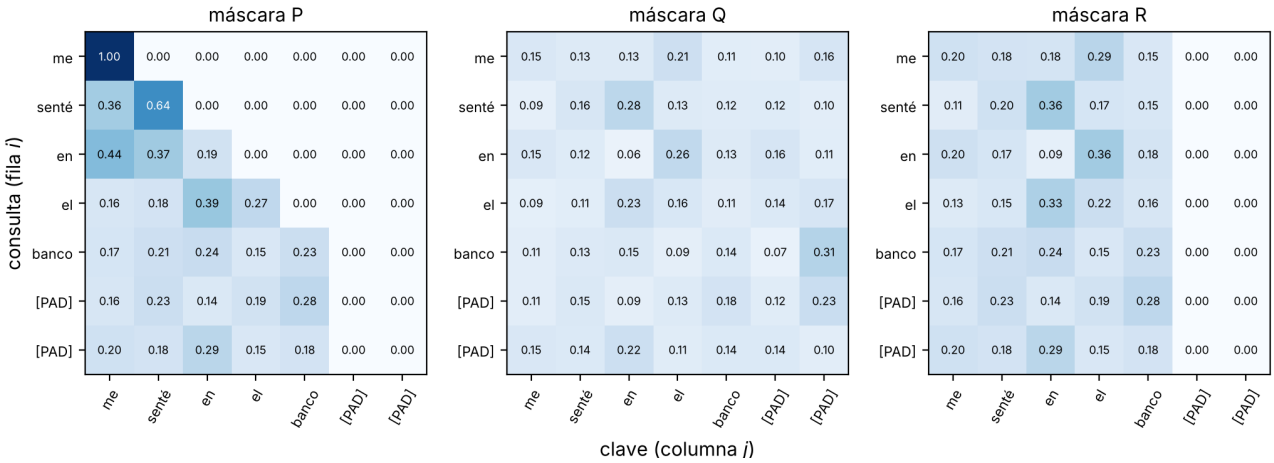
a) Sin atención, ¿qué recibe el decoder del encoder? Con eso, explica por qué $d = 24$ falla y $d = 96$ no.

b) Los errores se concentran en el día y el mes. Mira el orden de la frase de entrada: ¿por qué esos y no el año?

c) La atención agrega menos de 2 100 parámetros y resuelve la tarea con $d = 24$. ¿Qué cambia en lo que el decoder puede leer?

5. Máscaras y posiciones

La misma capa de autoatención sobre «me senté en el banco», rellenada con dos `[PAD]` para formar un lote. Cada mapa muestra los pesos de atención α_{ij} con una máscara distinta: ninguna, de relleno, o causal más relleno.



a) Asigna P, Q y R. Justifica cada una con lo que ves en el mapa.

b) ¿Qué problema produce Q en un lote con frases de distinto largo?

c) Sin embeddings de posición, se reordenan las cinco palabras y se pasan por la misma capa: las salidas son las mismas, en el nuevo orden (diferencia máxima $9 \cdot 10^{-8}$). Con posiciones, la diferencia es 0.23. ¿Por qué? ¿Qué consecuencia tiene para «el perro mordió al hombre» y «el hombre mordió al perro»?

6. El Transformer de las fechas y su costo

La misma tarea de la pregunta 4 con un Transformer encoder-decoder, $d = 64$, 245 964 parámetros.

	exacta			año		-	mes		-	día	
con posición	0.999	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
sin posición	0.660	0.99	0.99	**0.72**	**0.67**	1.00	1.00	1.00	1.00	0.95	0.90

longitud T	128	256	512	1 024	2 048
memoria de la matriz de atención (MB)	0.25	1	4	16	64

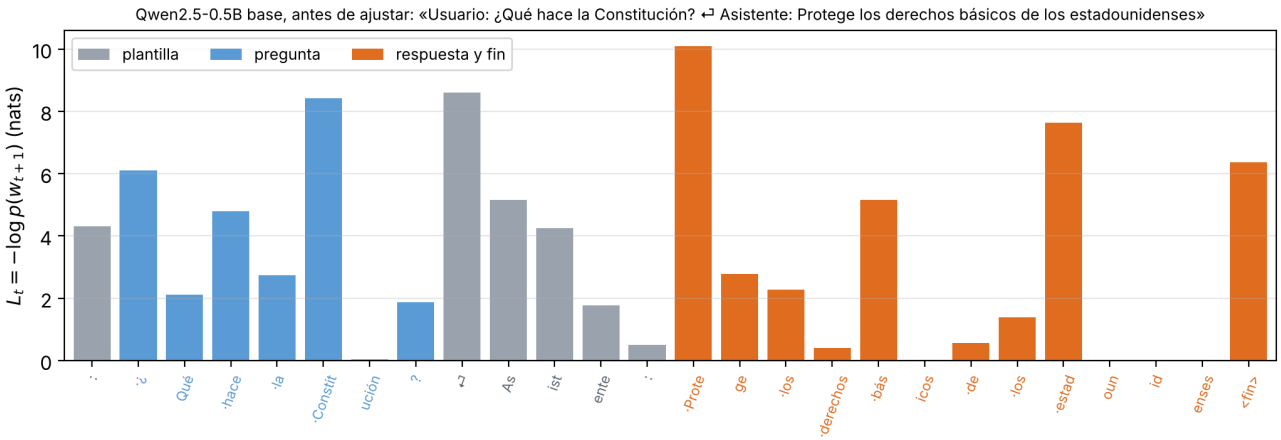
a) Sin posición, el modelo falla sobre todo en las dos últimas cifras del año, que en la entrada vienen como dígitos sueltos («2 0 2 6»), y nunca en el mes, que viene como palabra («mayo»). Explica por qué.

b) ¿Por qué factor crece la memoria de la atención cuando T se duplica? ¿Cuánta ocuparía con $T = 4\,096$?

c) ¿Cuántos parámetros tienen W_Q, W_K, W_V y W_O (con sesgo) de una capa de atención con $d = 64$? ¿Cambia ese número con T?

7. La pérdida del ajuste supervisado

Un par pregunta–respuesta de Dolly en la plantilla de chat. Cada barra es la pérdida de predecir ese token con el modelo base, antes de ajustarlo.



a) En el ajuste supervisado (SFT), ¿qué barras entran en la pérdida J y por qué las otras no? El promedio de las 26 barras es 3.36; el de las que cuentan, 2.82. ¿Cuál de los dos números optimiza el SFT?

b) Después de 250 pasos de LoRA, la J de validación pasa de 2.060 a 1.903 nats por token. Traduce los dos valores a perplejidad ($e^{2.06} \approx 7.8$, $e^{1.90} \approx 6.7$) y explica qué significa ese número.

c) De 12 preguntas, el modelo base se detiene solo en 2; después del ajuste, en 9. Pero ahora responde «Ballena: aves». ¿Qué aprendió el modelo en 250 pasos, y qué no?

d) ¿Se puede comparar esta J con la de otro modelo que usa otro tokenizador? ¿Por qué?

8. Elegir cómo usar un modelo preentrenado

IMDB con solo **2 000** reseñas de entrenamiento, 2 000 de test, GPU T4.

	acc. test	entrenables	tiempo	memoria
LSTM desde cero	0.778	4.2 M	15 s	0.7 GB
DistilBERT congelado + sonda logística sobre `[CLS]`	0.801	769	13 s	1.0 GB
DistilBERT ajustado completo	0.886	67 M	40 s	2.2 GB
DistilBERT + LoRA ($r = 8$, W_Q y W_V) + cabeza	0.891	740 k	34 s	1.5 GB

a) La LSTM entrena más parámetros que LoRA y queda 11 puntos por debajo. ¿Qué es lo que compra la exactitud, si no son los parámetros entrenables?

b) ¿Por qué el modelo congelado con sonda queda tan por debajo de los ajustados, si usa el mismo DistilBERT?

c) Una clínica tiene 800 notas clínicas en español etiquetadas para **tres** tareas distintas y una GPU de 16 GB. ¿Qué estrategia eliges y qué cambiarías del experimento de arriba? Nombra la línea base contra la que la compararías.